

UNIVERSIDADE DO MINHO
MESTRADO INTEGRADO EM ENGENHARIA INFORMÁTICA
DEPARTAMENTO DE INFORMÁTICA

GRAMÁTICAS NAS COMPREENSÃO DE SOFTWARE

Simulação de Q&A Systems

Grupo 2

Eduardo Gil Ribeiro da Rocha - **A77048**
Manuel Gouveia Carneiro de Sousa - **A78869**

5 de Fevereiro de 2019

Resumo

Este relatório pretende explicar quais os passos tomados para o desenvolvimento de um trabalho sobre sistemas $Q\mathcal{E}A$, abordando também as propriedades das tecnologias utilizadas.

Conteúdo

1	Introdução	3
2	Background	3
3	Trabalho Desenvolvido	3
3.1	Estruturação da Base de Conhecimento	4
3.2	Reconhecimento da Base de Conhecimento	4
3.2.1	Estruturação da Informação	5
3.2.2	Processamento de Informação	6
4	Conclusão	9
5	Anexos	10
5.1	Gramática Independente de Contexto	10
5.2	Gramática de Atributos	11

1 Introdução

No âmbito da Unidade Curricular de *Gramáticas na Compreensão de Software*, foi-nos proposto o desenvolvimento de uma *DSL* com o intuito de simular um sistema de Pergunta-Resposta. Este sistema, iria conter uma Base de Conhecimento formada por pares (Questão, Resposta), em que a questão é modelada por um triplo, o qual continha o tipo da questão, a ação tomada e uma lista de objetos envolventes. Através desta modelação, era possível fornecer a respetiva resposta para uma determinada pergunta.

Posto isto, iremos detalhar as diversas etapas que constituíam o desenvolvimento da *DSL* proposta.

2 Background

Um sistema *Q&A* (*Question and Answer*) é um tipo de *software* desenhado para tentar responder a perguntas colocadas pelos utilizadores.

Existem diferentes tipos de sistemas *Q&A*, entre os quais sistemas que necessitam o envolvimento de outra pessoa para além do utilizador, para que possa responder às perguntas, e sistemas automáticos em que o *software* tem acesso a toda a informação que precisa para responder.

3 Trabalho Desenvolvido

Inicialmente, foi feita a escolha de uma área de conhecimento na qual iríamos focar a nossa *DSL*. Esta área de conhecimento foi, então, Cinema/-Cultura Cinematográfica. Posto isto, de forma a dar resposta aos desafios propostos no enunciado, resolvemos então dividir o desenvolvimento da *DSL* em duas partes. A primeira, era a estruturação da base do conhecimento, e a forma de como esta iria ser escrita. Numa segunda fase, passaríamos então ao desenho da *DSL*, e posteriormente à forma de processamento da informação que iria sendo reconhecida. Passaremos então à explicação de cada uma das partes.

3.1 Estruturação da Base de Conhecimento

Para o desenho da base de conhecimento, resolvemos tomar como inspiração as estruturas das linguagens mais famosas como *C* ou *Java*. Para dividir a Base de Conhecimento com as Questões propriamente ditas, identificamos cada um desses componentes com *keywords* explícitas. Depois, logo a seguir a cada *keyword*, e delimitado por chavetas ({ ... }) colocamos então os triplos correspondentes a cada pergunta na secção da base de conhecimento, e as questões completas na secção das mesmas.

```
BASE_CONHECIMENTO {
    (Tipo-Q, Ação, [Objeto]) = "RESPOSTA" ;
    (...)
}

QUESTOES {
    " Exemplo de uma questão ? " ;
    (...)
}
```

Vista a estrutura do ficheiro a ser analisado, passaremos então à gramática para reconhecer toda a informação nele contida.

3.2 Reconhecimento da Base de Conhecimento

Com o intuito de reconhecer a estrutura anteriormente desenhado, foi então criada uma *DSL* para reconhecer a Base de Conhecimento e posteriormente dar resposta aos diversos pedidos nela incluídos. Para isso, foi então escrita a gramática dessa *DSL*, com o auxílio da ferramenta *ANTLR*, o qual nos produzia o *parser* para a nossa linguagem.

Numa primeira fase, foi criada a “GIC” (Gramática Independente de Contexto) para dessa forma, estruturarmos a nossa gramática final, e testar o reconhecimento dos símbolos. Após o correto reconhecimento, partimos para a criação da “GA” (Gramática de Atributos), fazendo o uso de atributos para comunicar informação entre as diversas produções.

Posto isto, iremos então explicar como é que a informação reconhecida foi estruturada e posteriormente processada.

3.2.1 Estruturação da Informação

Para estruturar a informação que iria ser reconhecida na Base de Conhecimento, resolvemos fazer o uso da primitiva “@members” fornecida pelo *ANTLR*, e nesta foi declarada uma classe *Triplo*, a qual iria guardar a informação relativa a um triplo, contendo então duas *strings* relativas ao tipo de questão e à ação, e uma lista de *strings* que corresponde à lista dos objetos/*keywords* da questão. Para além disso, foi ainda declarada a estrutura de dados principal do programa, a qual iria associar a resposta (*String*) ao seu respetivo *Triplo*. Aqui, foi usada a estrutura de dados *HashMap* fornecida pelo *Java*.

```
@members {
    public class Triplo {
        String tipoQ;
        String acao;
        ArrayList<String> keywords;

        public Triplo() {
            this.tipoQ = "";
            this.acao = "";
            this.keywords = new ArrayList<String>();
        }

        public void setKeywords(ArrayList<String> keywords) {
            for (String s : keywords) {
                this.keywords.add(s);
            }
        }
    }

    // Estrutura de dados principal.
    Map<String, Triplo> triplos;
}
```

É importante realçar o facto da escolha de guardar esta estrutura de dados principal como uma variável global, visto que o número de acessos era elevado, e o transporte desta ao longo da gramática como um atributo iria produzir uma solução bastante caótica em termos de código escrito.

3.2.2 Processamento de Informação

Depois de reconhecida a Base de Conhecimento e processada a informação correspondente, eram então reconhecidos os símbolos correspondentes à estrutura das questões, e processada a informação respetiva. Uma questão era processada palavra a palavra, analisando assim a sua classe. Estas classes, são previamente definidas no *Lexer* da gramática. Aqui, estão contidos os diversos tipos de questões (Onde, Quem, ...), as ações tomadas numa questão (verbos) e, por fim, a identificação de determinantes ou preposições na frase.

```
questao returns[String tipo_Q, String verbo,
                  ArrayList<String> keywords, StringBuilder pergunta]
@init {
    $questao.keywords = new ArrayList<String>();
    $questao.pergunta = new StringBuilder();
}
: ( t=TIPO_Q
    { $questao.tipo_Q = $t.text;
      $questao.pergunta.append($t.text + " "); }
  | a=ACAO
    { $questao.verbo = $a.text;
      $questao.pergunta.append($a.text + " "); }
  | c=(DETERMINANTE | PREPOSICAO)
    { $questao.pergunta.append($c.text + " "); }
  | k=TEXTO
    { $questao.keywords.add($k.text);
      $questao.pergunta.append($k.text + " "); } )+
;
```

As questões eram então reconhecidas consoante o *Lexer* definido.

```
/* ANALISADOR LÉXICO */
```

```
TIPO_Q      : 'Qual' | 'Quem' | 'Quando' | 'Onde' ;
ACAO        : 'é' | 'foi' ;
DETERMINANTE : 'o' | 'a' | 'os' | 'as' ;
PREPOSICAO  : 'de' | 'da' | 'do' | 'em' | 'para' | 'sem' ;
(...)
```

Ao ser reconhecida e processada uma questão, era verificada a existência de uma resposta consoante a informação reconhecida (o tipo da questão, a ação e as *keywords*), e posteriormente escolhida a resposta mais adequada. Esta resposta, é baseada no número de *keywords* encontradas. Se esse número for igual ao número de *keywords* no triplo inicialmente reconhecido, então foi encontrada a resposta. Se isto nunca acontecer, a resposta irá ser aquela que tenha mais *keywords* iguais.

Esta foi então a produção correspondente a esse reconhecimento, bem como o algoritmo feito para encontrar a resposta correta, ou a mais próxima da verdadeira, consoante a informação na Base de Conhecimento.

```
string returns[int maxKeywords, int maxKeyFound,
               ArrayList<String> pergunta, String resp]
: "\" q=questao "?" "\" ";
{
    (...)

    for (String r : triplos.keySet()) {
        Triplo t = triplos.get(r);

        if ( tipoQ.equals(t.tipoQ) && acao.equals(t.acao) ) {
            $string.maxKeywords = t.keywords.size();
            // Guarda resposta atual na variável auxiliar.
            $string.resp = r;
            for (String k : keywords) {
                if (t.keywords.contains(k)) {
                    maxTmp++;
                }
            }
        }

        if (maxTmp == t.keywords.size()) {
            $string.maxKeyFound = maxTmp;
            break; // Foi encontrada a resposta!
        } else if (maxTmp > $string.maxKeyFound) {
            $string.maxKeyFound = maxTmp;
        }
    }
}
```



```

        maxTmp = 0;
    }
}
;

```

Este processamento é feito à medida em que é são reconhecidas as questões. Com isto, são então imprimidas para a consola as respetivas respostas escolhidas para a questão em causa.

```

questoes
@init {
    System.out.println("Respostas às questões processadas:");
}
: "QUESTOES" "{"
( s=string
{
    System.out.print("\n" + $s.pergunta.toString());
    System.out.println("? \nR: " + $s.resp +
                        " :: Keywords: " + $s.maxKeyFound + "/"
                        + $s.maxKeywords);
} )+
"}"
;

```

4 Conclusão

De acordo com os principais objetivos propostos no enunciado do trabalho, concluímos que estes foram atingidos com sucesso. De facto, fomos capazes de criar uma *DSL* a qual dá respostas a diversas perguntas com alguma estrutura.

Através deste trabalho, foi-nos possível testar um pouco de toda a potencialidade que a ferramenta *ANTLR* nos traz. Com o auxílio da linguagem *Java* e funcionalidades fornecidas pelo *ANTLR*, algum do processamento feito tornou-se bastante intuitivo. Para além disso, o facto de termos produzido uma Gramática de Atributos, e através dos atributos herdados e atributos sintetizados, facilitou a forma de como todas as produções comunicavam entre elas, permitindo assim a troca de informação.

Em suma, o trabalho realizado deixou-nos aprofundar os conhecimentos adquiridos na Unidade Curricular assim como entender as utilidades de Gramáticas de Atributos em diversas áreas de desenvolvimento de *software*.

5 Anexos

5.1 Gramática Independente de Contexto

```
grammar BC_QA_GIC;

insts : base questoes
;

/* Processamento Base de Conhecimento */

base : 'BASE_CONHECIMENTO' '{' triplos '}'
;

triplos : (triplo)+
;

triplo : '(' tipoQ ',' acao ',' '[' objetos ']' ')'
        '=' '\"' resposta '\"' ';'
;

tipoQ : TIPO_Q
;

acao : ACAO
;

objetos : TEXTO (',' TEXTO)*
;

resposta : NUMERO
          | TEXTO (TEXTO)*
;

/* Processamento Questões */
```

```

questoes : 'QUESTOES' '{' (string)+ '}'
;

string : '\"' questao '?' '\"' ';'
;

questao : ( TIPO_Q | ACAA | (DETERMINANTE | PREPOSICAO) | TEXTO )+
;

/* ANALISADOR LÉXICO */

TIPO_Q      : 'Qual' | 'Quem' | 'Quando' | 'Onde' ;
ACAA        : 'é' | 'foi' ;
DETERMINANTE : 'o' | 'a' | 'os' | 'as' ;
PREPOSICAO  : 'de' | 'da' | 'do' | 'em' | 'para' | 'sem' ;

NUMERO      : [0-9]+ ;
TEXTO       : (LETRA)+ ;

Separador: ('\\r'? '\\n' | ' ' | '\\t')+ -> skip ;

/* LETRA não é um terminal.
   Simplesmente foi definido para simplificar
   outras expressões regulares. */
fragment LETRA : [a-zA-ZáéíóúÁÊÍÓÚãæïòûÂÊÎÔÛäöÅÕæìòùÀÈÌÒÙç_] ;

```

5.2 Gramática de Atributos

```

grammar BC_QA_GA;

@header {
    import java.util.Map;
    import java.util.HashMap;
    import java.util.List;
    import java.util.ArrayList;
}

```

```

@members {
    public class Triplo {
        String tipoQ;
        String acao;
        ArrayList<String> keywords;

        public Triplo() {
            this.tipoQ = "";
            this.acao = "";
            this.keywords = new ArrayList<String>();
        }

        public void setKeywords(ArrayList<String> keywords) {
            for (String s : keywords) {
                this.keywords.add(s);
            }
        }
    }

    // Estrutura de dados principal.
    Map<String, Triplo> triplos;
}

insts
@init {
    // Iniciar o mapeamento de triplos.
    triplos = new HashMap<String, Triplo>();
}

    : base questoes
;

/* Processamento Base de Conhecimento */

base      : 'BASE_CONHECIMENTO' '{' triplos '}'
;

```

```

triplos : (triplo)+
;

triplo  : '(' t=tipoQ ',' a=acao ',' '[' o=objetos ']' ' ' )'
        '=' '\'' r=resposta '\'' ';'
        {
            Triplo t = new Triplo();
            t.tipoQ = $t.text;
            t.acao = $a.text;
            t.setKeywords($o.keywords);

            triplos.put($r.resp, t);
        }
;

tipoQ    : TIPO_Q
;

acao     : ACAO
;

objetos returns[ArrayList<String> keywords]
        : t1=TEXTO { $objetos.keywords = new ArrayList<>();
                    $objetos.keywords.add($t1.text); }
        (',' t2=TEXTO { $objetos.keywords.add($t2.text); } ) *
;

resposta returns[String resp]
        : n=NUMERO { $resposta.resp = $n.text; }
        | t1=TEXTO { $resposta.resp = $t1.text; }
        (t2=TEXTO { $resposta.resp += (" " + $t2.text); } ) *
;

/* Processamento Questões */

questoes
@init {

```

```

        System.out.println("Respostas às questões processadas:");
    }
    : 'QUESTOES' '{'
        ( s=string
            {
                System.out.print("\n" + $s.pergunta.toString());
                System.out.println("? \nR: " + $s.resp +
                                    " :: Keywords: " + $s.maxKeyFound + "/"
                                    + $s.maxKeywords);
            }
        )+
    '}'
;

string returns[int maxKeywords, int maxKeyFound,
               StringBuilder pergunta, String resp]
: '\'' q=questao '?' '\'' ';'
{
    $string.maxKeywords = 0;
    $string.maxKeyFound = 0;
    $string.pergunta = $q.pergunta;
    $string.resp = "ERRO! Não foi encontrada resposta.";

    String tipoQ = $q.tipo_Q;
    String acao = $q.verbo;
    ArrayList<String> keywords = $q.keywords;

    int maxTmp = 0;

    for (String r : triplos.keySet()) {
        Triplo t = triplos.get(r);

        if ( tipoQ.equals(t.tipoQ) && acao.equals(t.acao) ) {
            $string.maxKeywords = t.keywords.size();
            // Guarda resposta atual na variável auxiliar.
            $string.resp = r;
            for (String k : keywords) {
                if (t.keywords.contains(k)) {

```

```

        maxTmp++;
    }
}

if (maxTmp == t.keywords.size()) {
    $string.maxKeyFound = maxTmp;
    break; // Foi encontrada a resposta!
} else if (maxTmp > $string.maxKeyFound) {
    $string.maxKeyFound = maxTmp;
}

maxTmp = 0;
}
}

;

questao returns[String tipo_Q, String verbo,
                  ArrayList<String> keywords, StringBuilder pergunta]
@init {
    $questao.keywords = new ArrayList<String>();
    $questao.pergunta = new StringBuilder();
}

: ( t=TIPO_Q
    { $questao.tipo_Q = $t.text;
      $questao.pergunta.append($t.text + " "); }
| a=ACAO
    { $questao.verbo = $a.text;
      $questao.pergunta.append($a.text + " "); }
| c=(DETERMINANTE | PREPOSICAO)
    { $questao.pergunta.append($c.text + " "); }
| k=TEXTO
    { $questao.keywords.add($k.text);
      $questao.pergunta.append($k.text + " "); } )+

;

/* ANALISADOR LÉXICO */

```



```

TIPO_Q      : 'Qual' | 'Quem' | 'Quando' | 'Onde' ;
ACAO        : 'é' | 'foi' ;
DETERMINANTE : 'o' | 'a' | 'os' | 'as' ;
PREPOSICAO  : 'de' | 'da' | 'do' | 'em' | 'para' | 'sem' ;

NUMERO      : [0-9]+ ;
TEXTO       : (LETRA)+ ;

Separador: ('\\r'? '\\n' | ' ' | '\\t')+ -> skip ;

/* LETRA não é um terminal.
   Simplesmente foi definido para simplificar
   outras expressões regulares. */
fragment LETRA : [a-zA-ZáéíóúÁÉÍÓÚâêîôûÂÊÎÔÛãõÃÕàèìòùÀÈÌÒÙçÇ_] ;

```

Referências

- [1] https://en.wikipedia.org/wiki/Q%26A_software
- [2] <https://wwwantlr3.org/works/>